

Introdução ao R e RStudio para Análise de Dados em Saúde

Curso preparatório presencial é online

Público: Estudantes e profissionais da saúde sem experiência prévia com R.

Coordenação:

Profa. Dra. Érika Fialho.

Prof. Dr. Cleanderson Fidelis.

Preparação para os cursos: Acesso, organização e análise de grandes bases do OPENDATASUS.

Importação e organização básica de dados

Objetivos do encontro

Ao final do segundo encontro, o participante deverá ser capaz de:

- reconhecer os principais formatos de arquivos;
- importar arquivos CSV e Excel;
- inspecionar a estrutura de uma base;
- selecionar, filtrar, renomear e criar variáveis;
- produzir resumos descritivos simples;
- salvar a base organizada.

Conteúdo detalhado do encontro 2

Estrutura de uma base

Linhas como observações e colunas como variáveis.

Identificadores e unidade de análise.

Variáveis numéricas, categóricas, lógicas e datas.

Valores ausentes e códigos utilizados em sistemas de informação em saúde.

Vetor, Matriz e Data.frame - qual a diferença?

No R, tudo que a gente usa em saúde é construído com 3 blocos:

1. Vetor: é uma coluna. Uma única variável. Ex: `idade <- c(20, 30, 40)` - só guarda um tipo.
2. Matriz: são vários vetores colados, mas todos do MESMO tipo. 2 dimensões. Não usamos muito em saúde porque no SUS a gente mistura número e texto.
3. <http://Data.frame> / tibble: é o que usamos no curso. Parece uma matriz, mas cada coluna pode ter um tipo diferente (`idade=número`, `sexo=texto`). É a planilha do Excel que o R entende. `[linha][coluna]`

Na matriz de dados abaixo, quantas variáveis e quantas observações existem?

id	idade	sexo	altura
1	9	F	120
2	56	M	160
3	28	M	190
4	40	F	170
5	50	M	155

- A) 3 variáveis e 2 observações.
- B) 4 variáveis e 5 observações.
- C) 5 variáveis e 4 observações.
- D) 4 variáveis e 3 observações.

Com os seus dados:

```
library(tidyverse)

dados <- data.frame(
  id = c(1, 2, 3, 4, 5),
  idade = c(9, 56, 28, 40, 50),
  sexo = c("F", "M", "M", "F", "M"),
  altura = c(120, 160, 190, 170, 155)
)
```

```
# Opção 2 - do jeito tidyverse (que a gente vai usar no curso)
dados <- tribble(
```

```
~id, ~idade, ~sexo, ~altura,  
1, 9, "F", 120,  
2, 56, "M", 160,  
3, 28, "M", 190,  
4, 40, "F", 170,  
5, 50, "M", 155  
)
```

```
dados # olha a tabela
```

Quantas linhas?

```
# Quantas linhas? (pacientes)  
nrow(dados)
```

```
[1] 5
```

Quantas colunas?

```
# Quantas colunas? (variáveis)  
ncol(dados)
```

```
[1] 4
```

Os dois de uma vez - linhas e colunas.

```
# Os dois de uma vez - linhas e colunas  
dim(dados)
```

```
[1] 5 4
```

5 linhas, 4 colunas

Para ver tudo (que vamos usar)

```
dim(dados) # no SIM com 50 mil linhas é essencial
```

Do mais simples ao que vamos usar no curso:

1. Jeito cifrão \$

```
#Jeito cifrão $  
dados$idade  
[1] 9 56 28 40 50
```

2. Jeito colchete - pega como tabela (mantém o nome em cima)

```
# Jeito colchete - pega como tabela (mantém o nome em cima)
dados["idade"]
dados[, "idade"]
```

3. Jeito tidyverse - o que vamos usar da Aula 2 em diante

```
library(dplyr)
select(dados, idade)
```

mais de uma coluna?

```
# mais de uma coluna?
select(dados, idade, altura)
select(dados, sexo, altura)
```

Apagar coluna

```
# Só mostra (não salva)
select(dados, -altura)
```

2. Agora sim apaga e guarda no caderno

```
# 2. Agora sim apaga e guarda no caderno
dados <- select(dados, -altura)
```

pronto, agora se você digitar dados, altura sumiu

dados.

Pacotes essenciais

tidyverse=Conjunto principal de pacotes para organização e análise.

readr=Importação e exportação de arquivos CSV.

readxl=Importação de planilhas Excel.

dplyr=Seleção, filtragem, transformação e resumo.


stringr=Tratamento de textos.

lubridate=Tratamento de datas.

janitor=Padronização de nomes e tabelas simples.

here =Organização dos caminhos dos arquivos.

O pacote microdatasus poderá ser apresentado brevemente no encerramento, mas sua instalação e utilização devem integrar o curso principal, quando serão discutidos o acesso, o download, o processamento e as particularidades dos diferentes sistemas de informação do SUS.



Botão Import Dataset do RStudio

No RStudio tem um botão que é igual ao "Abrir" do Excel. Fica no canto superior direito, na aba *Environment*.

Passo a passo na tela:

1. Clica em Environment > Import Dataset > From Text (readr) para CSV ou From Excel
2. Clica em Browse e escolhe o arquivo exemplo_saude.csv
3. Na prévia, confere se as colunas apareceram certas
4. **IMPORTANTE:** lá embaixo tem um quadradinho de código. Copia esse código e cola no seu script.

Esse código o RStudio gera sozinho para você:

```
dados_csv <- read_csv("dados/exemplo_saude.csv")
```

Isso! No botão *Import Dataset* tem 3 opções principais. É para isso:

1. *From Text (readr)* -> para CSV

É seu arquivo padrão do OpenDataSUS.

Termina com .csv

Quando usar: SIM, SINASC, SIH que você baixou do governo. É vírgula ou ponto-e-vírgula separando as colunas.

1. From Excel -> para XLSX

É o arquivo que vem da secretaria, do hospital.

Termina com .xlsx ou .xls

Quando usar: planilha que a coordenação te mandou no WhatsApp.

1. From SPSS / SAS / Stata -> para pesquisa


Arquivos de outros programas de estatística.


Termina com .sav, .dta

Quando usar: quando você recebe base de pesquisa de TCC, mestrado.

Resumo:

"Se veio do Ministério = From Text (CSV). Se veio da secretaria/hospital em planilha = From Excel. O R vai ler igual, só muda o botão."





De onde vêm estes dados

Diferente do resto do curso (que usa exemplos fictícios), aqui usamos um dado REAL: o cadastro de Unidades Básicas de Saúde (UBS) do Brasil inteiro, baixado do Portal de Dados Abertos do SUS. Para baixar você mesmo(a):

1. Acesse <https://dadosabertos.saude.gov.br/dataset>
2. Use o filtro "Formatos" na lateral e escolha CSV
3. Procure o conjunto "Unidades Básicas de Saúde (UBS)"
4. Baixe o arquivo .zip e extraia o .csv

O processo de importação no R é sempre o mesmo, seja qual for a base que você baixar só muda o nome do arquivo.

```
# Importação
library(readr)
library(readxl)

dados_csv <- read_csv("dados/exemplo_saude.csv")

dados_excel <- read_excel(
  "dados/exemplo_saude.xlsx",
```

```
sheet = 1  
)
```

A importação pela interface do RStudio poderá ser demonstrada para facilitar a compreensão inicial. Entretanto, o comando correspondente deverá ser mantido no script para que a análise possa ser reproduzida.

```
# Inspeção  
head(dados_excel)      # Exibe as 6 primeiras linhas  
names(dados_excel)     # Lista o nome de todas as colunas  
dim(dados_excel)       # Retorna o número de linhas (observações)  
e colunas (variáveis).  
str(dados_excel)       # Mostra a estrutura interna e tipos de  
dados.  
summary(dados_excel)   # Produz o resumo estatístico preliminar  
glimpse(dados_excel)   # Visão rápida e compacta do dataframe  
(dplyr).
```

A turma deverá interpretar o número de observações e variáveis, os nomes das colunas, os tipos reconhecidos pelo R e a presença de valores ausentes.

```
# Organização com dplyr  
  
dados_organizados <- dados_csv |>  
  select(id, idade, sexo, municipio, desfecho) |>  
  filter(idade >= 18) |>  
  rename(  
    codigo = id,  
    municipio_residencia = municipio  
  ) |>  
  mutate(  
    faixa_etaria = case_when(  
      idade < 30 ~ "18-29",  
      idade < 60 ~ "30-59",  
      idade >= 60 ~ "60 ou mais",  
      TRUE ~ NA_character_  
    )  
  )  
)
```

As funções prioritárias serão select, filter, rename, mutate, case_when, arrange, count, group_by e summarise. Junções, pivoteamento, programação, criação de funções e visualizações complexas serão reservados ao curso principal.


```
# Resumos descritivos
dados_organizados |>
  count(sexo)

dados_organizados |>
  count(faixa_etaria)

dados_organizados |>
  group_by(sexo) |>
  summarise(
    numero = n(),
    idade_media = mean(idade, na.rm = TRUE)
  )
Salvamento
write_csv(
  dados_organizados,
  "resultados/dados_organizados.csv"
)

saveRDS(
  dados_organizados,
  "resultados/dados_organizados.rds"
)
```

Desafio Final

```
#Desafio Final
# 1. importar
dados <- read_csv(here("dados", "Mortalidade_Geral_2026.csv"))

# 2. dimensões
dim(dados)

# 3. nomes e tipos
names(dados)
glimpse(dados)

# 4. selecionar
dados_sel <- dados |> select(id, idade, sexo, municipio, desfecho)

# 5. filtrar
dados_sel <- dados_sel |> filter(idade >= 18)
```

```
# 6. criar categórica
dados_sel <- dados_sel |>
  mutate(faixa_etaria = case_when(
    idade < 30 ~ "18-29",
    idade < 60 ~ "30-59",
    idade >= 60 ~ "60 ou mais",
    TRUE ~ NA_character_
  ))

# 7. frequências
dados_sel |> count(sexo)
dados_sel |> count(faixa_etaria)

# 8. salvar - CORRIGIDO com here()
write_csv(dados_sel, here("resultados", "dados_organizados.csv"))
saveRDS(dados_sel, here("resultados", "dados_organizados.rds"))
```

Produto do encontro 2

Cada participante deverá concluir um script reproduzível que registre o fluxo importar, inspecionar, organizar, resumir e salvar. O arquivo final servirá como modelo inicial para as atividades a serem desenvolvidas nos cursos posteriores.